



**ИНСТИТУТ ИНТЕЛЛЕКТУАЛЬНЫХ  
КИБЕРНЕТИЧЕСКИХ СИСТЕМ**

**Кафедра  
«Криптология и Кибербезопасность»**

---

**ОТЧЕТ  
ПО ДОМАШНЕМУ ЗАДАНИЮ №1 ПО ДИСЦИПЛИНЕ  
«Биоинспирированные алгоритмы решения задач защиты  
информации»**

Выполнил:  
студент гр. Б21-515

Черняков А. В.

Преподаватель:

Борзунов Г. И.

---

**Москва - 2025**

---

## СОДЕРЖАНИЕ

ХОД ВЫПОЛНЕНИЯ.....	2
1 Программная реализация генетического алгоритма.....	2
2 Исследование зависимости результатов работы алгоритма от основных параметров алгоритма.....	4
2.1 Зависимость от мощности популяции.....	4
2.2 Зависимость от вероятности скрещивания.....	8
2.3 Зависимость от вероятности мутации.....	10
3 Найденные решения на графике функции.....	12
4 Сравнение результатов с действительным максимумом.....	14
ЗАКЛЮЧЕНИЕ.....	15
СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ.....	17
Приложение А.....	18
Приложение В.....	21

## ХОД ВЫПОЛНЕНИЯ

### 1 Программная реализация генетического алгоритма

По условию необходимо было реализовать генетический алгоритм для нахождения максимума функции

$$f(x) = \frac{\cos(x^e)}{\sin(\ln(x))}$$

на отрезке  $[2; 4]$ .

Для реализации алгоритма был выбран язык программирования Golang. Из особенностей реализации можно отметить применение одноточечного скрещивания. В качестве мутации применялась функция, изменяющая значение особи на случайную величину от -0.05 до 0.05 (в случае выхода за пределы заданного интервала особи присваивалось значение краевой точки). Полный код, реализующий данный алгоритм представлен в приложении А.

Пример работы программы представлен на рисунке 1.

```

● PS C:\Users\a.chernyakov\Desktop\BioAlg\Homework1> go run .\geneticalgorithm.go
Поколение 0: x = 2.5203594440; f(x) = 1.2416097410
Поколение 1: x = 2.5354872364; f(x) = 1.2451456305
Поколение 2: x = 2.5238921332; f(x) = 1.2464156658
Поколение 3: x = 2.5276493343; f(x) = 1.2488849203
Поколение 4: x = 2.5276493343; f(x) = 1.2488849203
Поколение 5: x = 2.5287819982; f(x) = 1.2490904699
Поколение 6: x = 2.5292328805; f(x) = 1.2491024961
Поколение 7: x = 2.5290686916; f(x) = 1.2491027238
Поколение 8: x = 2.5291511305; f(x) = 1.2491032693
Поколение 9: x = 2.5291511305; f(x) = 1.2491032693
Поколение 10: x = 2.5291482918; f(x) = 1.2491032726
Поколение 11: x = 2.5291439934; f(x) = 1.2491032746
Поколение 12: x = 2.5291439934; f(x) = 1.2491032746
Поколение 13: x = 2.5291439934; f(x) = 1.2491032746
Поколение 14: x = 2.5291436691; f(x) = 1.2491032746
Поколение 15: x = 2.5291436691; f(x) = 1.2491032746
Поколение 16: x = 2.5291437085; f(x) = 1.2491032746
Поколение 17: x = 2.5291437085; f(x) = 1.2491032746
Поколение 18: x = 2.5291437085; f(x) = 1.2491032746
Поколение 19: x = 2.5291437085; f(x) = 1.2491032746
Поколение 20: x = 2.5291437076; f(x) = 1.2491032746
Поколение 21: x = 2.5291437076; f(x) = 1.2491032746
Поколение 22: x = 2.5291437080; f(x) = 1.2491032746
Поколение 23: x = 2.5291437080; f(x) = 1.2491032746
Поколение 24: x = 2.5291437080; f(x) = 1.2491032746
Поколение 25: x = 2.5291437080; f(x) = 1.2491032746
Поколение 26: x = 2.5291437080; f(x) = 1.2491032746
Поколение 27: x = 2.5291437080; f(x) = 1.2491032746
Поколение 28: x = 2.5291437080; f(x) = 1.2491032746
Поколение 29: x = 2.5291437080; f(x) = 1.2491032746
Поколение 30: x = 2.5291437080; f(x) = 1.2491032746
Поколение 31: x = 2.5291437080; f(x) = 1.2491032746
Поколение 32: x = 2.5291437080; f(x) = 1.2491032746
Поколение 33: x = 2.5291437080; f(x) = 1.2491032746
Поколение 34: x = 2.5291437080; f(x) = 1.2491032746
Поколение 35: x = 2.5291437080; f(x) = 1.2491032746
Поколение 36: x = 2.5291437080; f(x) = 1.2491032746
Поколение 37: x = 2.5291437080; f(x) = 1.2491032746
Поколение 38: x = 2.5291437080; f(x) = 1.2491032746
Поколение 39: x = 2.5291437080; f(x) = 1.2491032746
Поколение 40: x = 2.5291437080; f(x) = 1.2491032746
Поколение 41: x = 2.5291437080; f(x) = 1.2491032746
Поколение 42: x = 2.5291437080; f(x) = 1.2491032746
Лучшее найденное решение: a(2.5291437080) = 1.2491032746
Время работы алгоритма: 5667 мс
○ PS C:\Users\a.chernyakov\Desktop\BioAlg\Homework1>

```

Рисунок 1 – Пример работы алгоритма

## **2 Исследование зависимости результатов работы алгоритма от основных параметров алгоритма**

На данном этапе выполнения домашнего задания были исследованы зависимости времени работы алгоритма, числа поколений и точности нахождения решения от мощности популяции и вероятностей скрещивания и мутации. Для каждой полученной зависимости был построен график.

### **2.1 Зависимость от мощности популяции**

Зависимость времени работы алгоритма от мощности множества определялась следующим образом. Для каждого из значений 30, 50, 75, 100, 125, 150, 175 и 200 для параметра мощности популяции было произведено по 10 запусков алгоритма и замерено время работы. После этого для каждого из значений было найдено среднее время работы. В результате измерений были получены данные, представленные в таблице 1.

Таблица 1 – Зависимость времени работы алгоритма от мощности популяции.

<b>N</b>	30	50	75	100	125	150	175	200
<b>t</b>	5,3	1,3	2,0	3,0	3,5	4,2	5,4	6,1

Аналогично были рассчитаны значения количества поколений для нахождения решения в зависимости от мощности популяции. Результаты представлены в таблице 2.

Таблица 2 – Зависимость числа поколений от мощности популяции.

<b>N</b>	30	50	75	100	125	150	175	200
<b>n</b>	33,5	42,3	38,9	37,7	41,0	39,8	40,3	41,8

Для нахождения точности найденного решения сначала было определено точное значение точки максимума данной функции на заданном отрезке. Для нахождения данного значения был использован инструмент Wolfram Alpha [1]. На основе расчётов на веб-сайте было определено, что

максимальное значение функции на заданном отрезке принимается при  $x = 2,5291437$  и равно оно  $1,2491$ . Результаты работы сервиса представлены на рисунке 2. На основе этого по формуле:

$$e = \left(1 - \frac{|x_{\text{действ.}} - x_{\text{ГА}}|}{|x_{\text{ГА}}|}\right) \times 100\%$$

была рассчитана точность решения, найденного генетическим алгоритмом. В результате получились данные, представленные в таблице 3.

Таблица 3 – Зависимость точности решения от мощности популяции.

N	30	50	75	100	125	150	175	200
e	99,98	99,92	99,98	100,00	99,93	99,98	100,00	100,00



Рисунок 2 – Максимальное значение функции на заданном отрезке.

На основе представленных данных были построены графики зависимости данных величин от мощности популяции. Графики зависимости времени работы алгоритма, числа поколений и точности решений представлены на рисунках 3-5 соответственно.

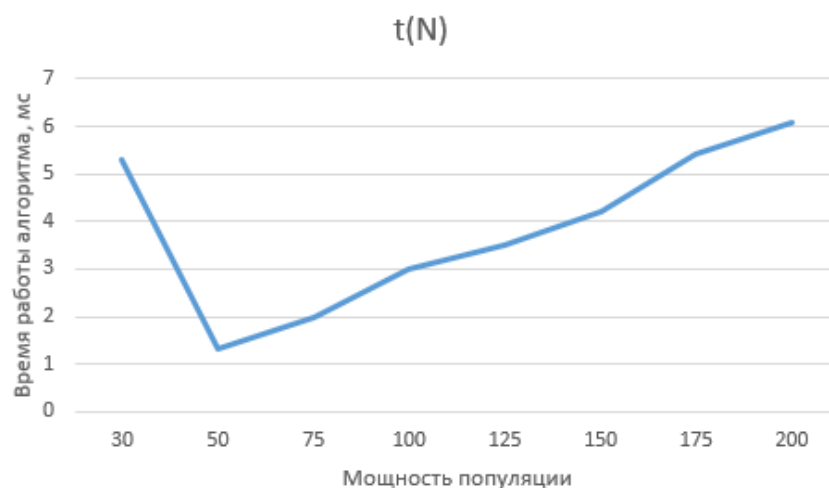


Рисунок 3 – График зависимости времени работы от мощности популяции.

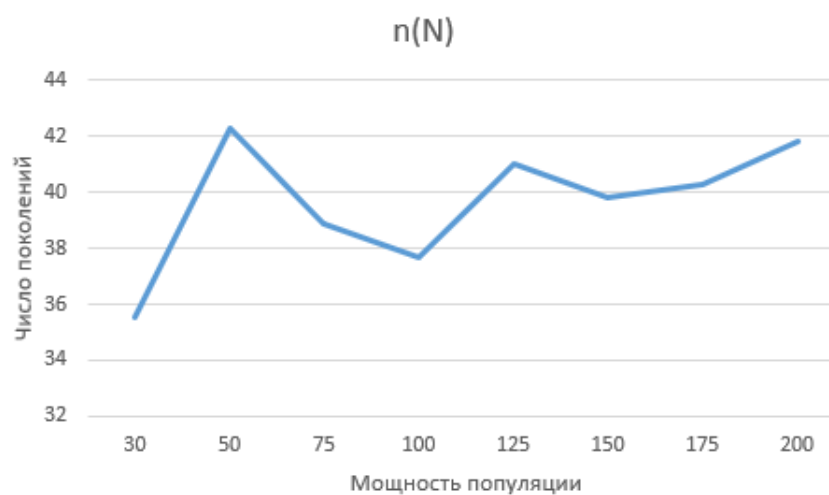


Рисунок 4 – График зависимости числа поколений от мощности популяции.




Рисунок 5 – График зависимости точности решения от мощности популяции.



## 2.2 Зависимость от вероятности скрещивания

Аналогично для нахождения зависимости времени работы алгоритма, числа поколений и точности решения от вероятности скрещивания было произведено по 10 запусков алгоритма со значениями вероятности скрещивания 0.05, 0.08, 0.11, 0.14, 0.17, 0.20, 0.23, 0,25. После чего для каждого из значений было найдено среднее значение результатов работы. Исходя из этого были получены зависимости описанных характеристик работы алгоритма от параметра вероятность скрещивания. Зависимости представлены в таблицах 4-6 соответственно (для большей точности определения времени работы алгоритма мощность популяции была установлена 200, а точность найденного решения вычислялась по формуле аналогичной прошлому разделу).

Таблица 4 – Зависимость времени работы алгоритма от вероятности скрещивания.

$P_c$	0,50	0,55	0,60	0,65	0,70	0,75	0,80	0,85
t	6,2	6,3	6,5	6,5	6,6	6,8	6,5	6,4

Таблица 5 – Зависимость числа поколений от вероятности скрещивания.

$P_c$	0,50	0,55	0,60	0,65	0,70	0,75	0,80	0,85
n	39,9	40,7	40,8	39,4	40,3	36,3	36,2	33,0

Таблица 6 – Зависимость точности решения от вероятности скрещивания.

$P_c$	0,50	0,55	0,60	0,65	0,70	0,75	0,80	0,85
e	99,98	100,00	100,00	100,00	100,00	100,00	99,99	99,99

Затем были построены графики данных зависимостей, представленные на рисунках 6-8 соответственно.




Рисунок 6 – График зависимости времени работы алгоритма от вероятности скрещивания.

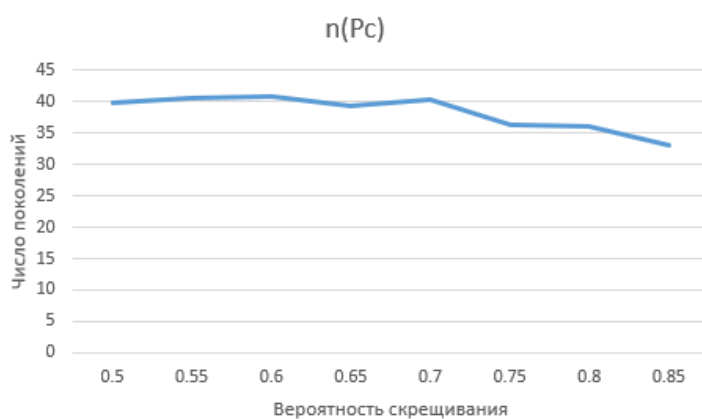


Рисунок 7 – График зависимости числа поколений от вероятности скрещивания.

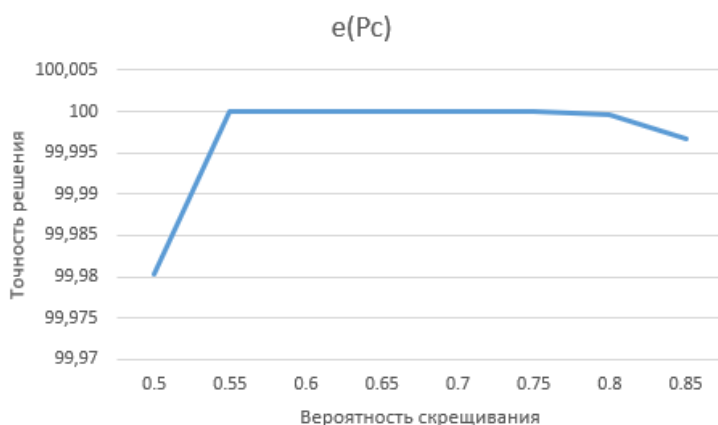


Рисунок 8 – График зависимости точности решения от вероятности скрещивания.

### 2.3 Зависимость от вероятности мутации

Аналогичный порядок действий был проделан для вероятности мутации, принимавшей значения 0.05, 0.08, 0.11, 0.14, 0.17, 0.20, 0.23 и 0.25. Исходя из этого были получены зависимости времени работы алгоритма, числа поколений и точности найденного решения от вероятности мутации. Данные зависимости представлены в таблицах 7-9 соответственно.

Таблица 7 – Зависимость времени работы алгоритма от вероятности мутации.

$P_m$	0,05	0,08	0,11	0,14	0,17	0,20	0,23	0,25
t	6,6	7,0	6,7	6,0	7,8	6,7	6,9	7,3

Таблица 8 – Зависимость числа поколений от вероятности мутации.

$P_m$	0,05	0,08	0,11	0,14	0,17	0,20	0,23	0,25
n	41,5	40,4	40,8	42,1	44,8	44,7	42,7	41,2

Таблица 9 – Зависимость точности решения от вероятности мутации.

$P_m$	0,05	0,08	0,11	0,14	0,17	0,20	0,23	0,25
e	100,00	100,00	99,99	99,99	100,00	100,00	100,00	100,00

На основе данных зависимостей были построены графики, представленные на рисунках 9-11 соответственно.

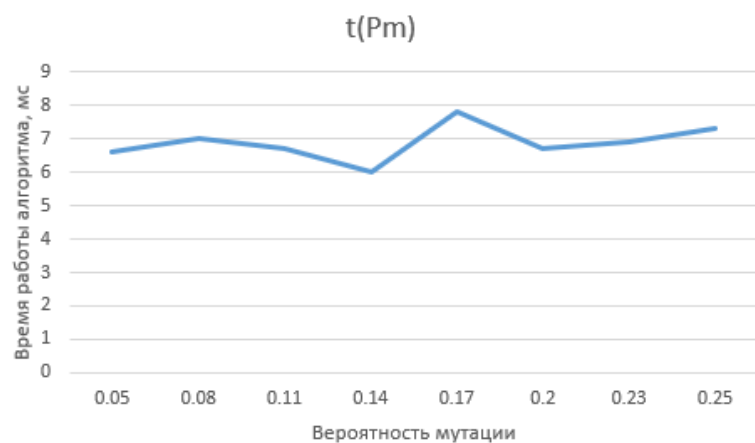


Рисунок 9 – График зависимости времени работы алгоритма от вероятности мутации.

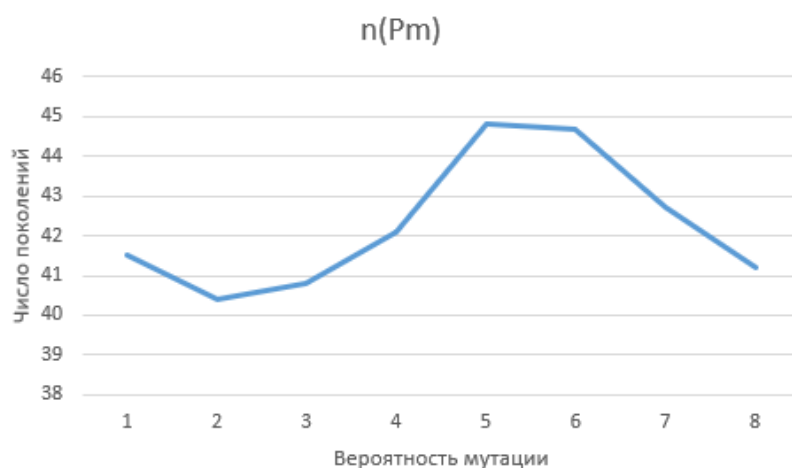


Рисунок 10 – График зависимости числа поколений от вероятности мутации.

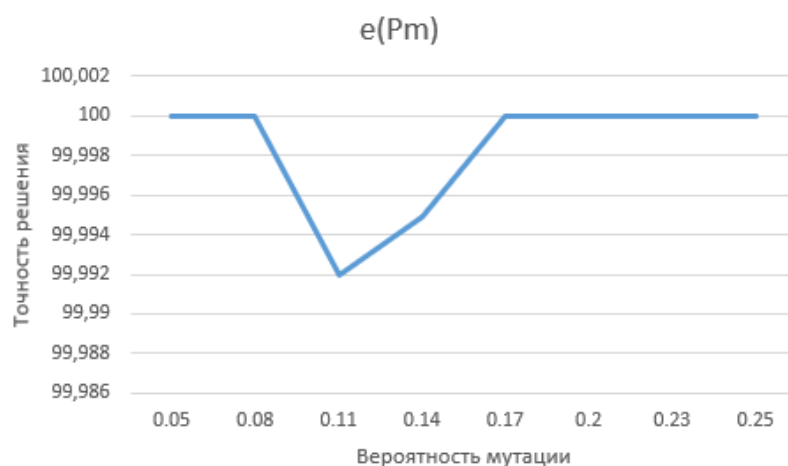


Рисунок 11 – График зависимости точности решения от вероятности мутации.

### 3 Найденные решения на графике функции

Следующим шагом стало построение графика функции, на котором отмечен лучший результат для каждого из поколений. Лучшее значение для каждого поколения, полученное в ходе выполнения алгоритма и использованное для построения графика представлено в таблице 10. Для построения графика с отмеченными точками был написан скрипт на языке программирования Python. Исходный текст данного скрипта представлен в приложении В. Также для удобства восприятия был добавлен функционал, который отмечает значения более ранних поколений цветами ближе к красному, а результаты последних поколений цветами ближе к зелёному (для читаемости графика рассматривались лишь уникальные значения, полученные различными поколениями).

Таблица 10 – Лучшие особи для каждого поколения.

Номер поколения	Лучшее значение (особь)
1	2,4972344340
2	2,5023601253
3-5	2,5369055717
6-12	2,5289099216
13-16	2,5291679324
17-18	2,5291437383
19	2,5291436950
20-21	2,5291437151
22	2,5291437105
23-25	2,5291437069
26-27	2,5291437078
28-48	2,5291437086

При запуске данного скрипта с представленными значениями был получен график, представленный на рисунке 12.




Рисунок 12 – График функции с лучшими значениями на каждом поколении.

#### 4 Сравнение результатов с действительным максимумом

В итоге при помощи данного алгоритма (при нескольких запусках с различными параметрами) наиболее точное решение которое удалось получить составило 2,529143708 (параметры запуска:  $N = 200$ ,  $P_c = 0.55-0.75$ ,  $P_m = 0.1$ ) при действительном значении 2,5291437 (максимальное число знаков после запятой, которое выдавал используемый сервис).

Таким образом можно сделать вывод, что алгоритм показал себя хорошо и позволил определить максимум функции на заданном отрезке с точностью не меньше, чем седьмой знак после запятой.

## ЗАКЛЮЧЕНИЕ

В ходе данной лабораторной работы был реализован генетический алгоритм поиска максимума функции на заданном отрезке. При помощи данного алгоритма удалось получить решение с хорошей точностью.

Помимо этого в ходе работы был проанализированы зависимости времени работы алгоритма, числа поколений и точности решения от основных параметров генетических алгоритмов: мощности популяции и вероятностей скрещивания и мутации. По полученным значениям были построены графики, которые в целом подтверждают теоретические принципы работы алгоритма. По мере увеличения мощности популяции покрывается большая область значений, но при этом происходит проигрыш во времени его работы. Время работы алгоритма практически не изменяется при увеличении вероятностей скрещивания и мутации. Возможно, немного увеличивается при увеличении вероятностей, поскольку программе приходится производить больше операций для осуществления операций скрещивания и мутации, но это изменение не столь велико. А вот число поколений, необходимых для нахождения решения и точность найденного решения может значительно измениться при различных вероятностях. При увеличении вероятности скрещивания алгоритму требуется меньшее число поколений для нахождения оптимального решения, поскольку последующие поколения с большей вероятностью перенимают положительные качества предшествующего и получают результат точнее. При увеличении вероятности мутации же может произойти потеря полезных особей, из-за чего может вырасти число необходимых для нахождения решений поколений и потеряется точность полученного решения.

Финальным результатом работы стало построение графика функции с демонстрацией лучшего значения для каждого из поколения, на котором отчётливо видно, что каждое последующее поколение находит решение, отличающееся от действительного на всё меньшее и меньшее значение.



Таким образом, могу сделать вывод, что генетические алгоритмы действительно хорошо подходят для решения сложных задач, в которых пространство поиска слишком велико для применения традиционных методов (таких как перебор всех возможных вариантов), а также выделить на основе практической работы оптимальные для себя параметры генетического алгоритма, которые лучше всего себя показывают при решении подобных задач:

$$N = 100;$$

$$P_c = 0,65;$$

$$P_m = 0,08.$$

## **СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ**

- 1) Wolfram|Alpha: Computational Intelligence [Электронный ресурс]. URL: <https://www.wolframalpha.com/> (дата обращения 27.02.2025);

## Приложение А

```
package main

import (
    "fmt"
    "math"
    "math/rand"
    "time"
)

const (
    tournamentSize = 3
    popSize        = 200
    crossProb      = 0.7
    mutProb        = 0.1
    xMin           = 2.0
    xMax           = 4.0
    stagnationLimit = 20
)

func randChoice[T any](arr []T) T {
    return arr[rand.Intn(len(arr))]
}

func fitness(x float64) float64 {
    numerator := math.Cos(math.Exp(x))
    denominator := math.Sin(math.Log(x))
    return numerator / denominator
}

func genIndividual() float64 {
    return xMin + (xMax-xMin)*rand.Float64()
}

func genPopulation() ([]float64) {
    res = make([]float64, popSize)

    for i := range res {
        res[i] = genIndividual()
    }
    return
}

func tournamentSelection(population []float64) (best float64) {
    best = randChoice(population)
    for i := 1; i < tournamentSize; i++ {
        contender := randChoice(population)
        if fitness(contender) > fitness(best) {
            best = contender
        }
    }
    return
}
```

```

// Одноточечный кроссинговер
func crossover(p1, p2 float64) float64 {
    if rand.Float64() < crossProb {
        return (p1 + p2) / 2
    }
    return p1
}

func mutate(ind float64) float64 {
    if rand.Float64() < mutProb {
        delta := (rand.Float64() - 0.5) * 0.1
        mutant := ind + delta
        if mutant < xMin {
            mutant = xMin
        } else if mutant > xMax {
            mutant = xMax
        }
        return mutant
    }
    return ind
}

func main() {
    for range 10 {
        rand.Seed(time.Now().UnixNano())
        startTime := time.Now()

        population := genPopulation()
        bestIndividual := population[0]
        maxExtremum := fitness(bestIndividual)
        stagnationCount := 0
        generation := 0

        for stagnationCount < stagnationLimit {
            newPopulation := genPopulation()

            for i := range newPopulation {
                p1 := tournamentSelection(population)
                p2 := tournamentSelection(population)
                child := crossover(p1, p2)
                child = mutate(child)
                newPopulation[i] = child
            }
            population = newPopulation

            improved := false
            for _, ind := range population {
                value := fitness(ind)
                if value > maxExtremum {
                    bestIndividual = ind
                    maxExtremum = value
                    improved = true
                }
            }
        }
    }
}

```

```

    }

    if improved {
        stagnationCount = 0
    } else {
        stagnationCount++
    }

    fmt.Printf("Поколение %d: x = %.10f; f(x) = %.10f\n",
generation, bestIndividual, maxExtremum)
    generation++
}

workTime := time.Since(startTime)
fmt.Printf("Лучшее решение, найденное алгоритмом: f(%.10f) =
%.10f\n", bestIndividual, maxExtremum)
fmt.Printf("Затраченное время %d мс\n", workTime.Milliseconds())
}
}

```

## Приложение В

```
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.cm as cm
import matplotlib.colors as mcolors
import matplotlib

X_MIN = 2
X_MAX = 4

def f(x):
    return np.cos(np.exp(x)) / np.sin(np.log(x))

x_values = np.linspace(X_MIN, X_MAX, 400)
y_values = f(x_values)

file_path = r"Path_to_values"
with open(file_path, "r") as file:
    x_points = list(dict.fromkeys(float(line.strip()) for line in file))

y_points = f(np.array(x_points))

matplotlib.use('Agg')
norm = mcolors.Normalize(vmin=0, vmax=len(x_points) - 1)
cmap = plt.colormaps.get_cmap("RdYlGn")
colors = [cmap(norm(i)) for i in range(len(x_points))]

plt.figure(figsize=(8, 5))
plt.plot(x_values, y_values, label="f(x)", color="blue")

for i, (x, y) in enumerate(zip(x_points, y_points)):
    plt.scatter(x, y, color=colors[i], edgecolor='black', zorder=3)
    #plt.text(x, y, f"{y:.2f}", fontsize=9, ha='left', va='bottom')

plt.xlabel("x")
plt.ylabel("f(x)")
plt.title("График функции с отмеченными точками")
plt.legend()
plt.grid(True)
plt.savefig("save_path/plot.png", dpi=300)
```